축구 이벤트(Wyscout) 시퀀스를 활용한 고급 성능지표 학습 및 추론(xAction, xPass)과 지표 간 상관관계 분석

0. 초록

본 프로젝트는 축구 이벤트(Wyscout) 시퀀스를 입력으로 받아 ① 다음 액션을 예측(xAction)하고, ② 패스 성공 확률(xPass)을 학습·추론하며, ③ socceraction 라이브러리를 바탕으로 계산된 VAEP 값과의 관계를 분석하여 선수/경기 단위의 고급 성능지표 활용 가능성을 검증한다. 데이터는 Wyscout 기반 Atomic SPADL 포맷의 대규모 이벤트 로그(약 436만 액션)이며, 시계열·불균형·노이즈가 강한 환경에서 분류 모델(Transformer/GRU/LSTM)과 확률 예측 모델(XGBoost, lightGBM)을 학습한다. 또한 VAEP와 xActionResidual, xPaxxResidual 간 상관을 산출하여, “행동 예측의 품질/일관성”이 가치 지표(VAEP)와 연결될 가능성을 확인했으며, 분석 산출물을 JSON/CSV 형태로 정리해 웹/대시보드에서 소비 가능한 형태로 제공했다.

기여:

1. Wyscout → Atomic SPADL → (xAction/xPass) 학습·추론·요약까지 “재현 가능한 파이프라인”으로 구성하고, run 단위 산출물(JSON/CSV/log)을 체계적으로 저장했다.
2. 선수/경기(및 시즌) 단위에서 서로 다른 고급 지표를 동일 키로 정렬하여, 지표 간 상관관계(및 전통 지표 확장)를 정량적으로 수행할 수 있는 분석 구조를 제시했다.

---

1. 서론

1.1 문제 배경과 필요성

축구에서 선수의 팀 승리 기여도를 득점/도움만으로 측정하면 (i) 빈도 자체가 희소하고, (ii) 과정 기여(압박, 전개, 빌드업, 위험/가치 창출)를 반영하지 못한다. 따라서 이벤트 로그 기반의 고급 지표가 필요하며, 대표적으로 다음을 함께 다룬다.

- xPass: 이 패스가 성공할 확률을 추정해 의사결정의 난이도/품질을 반영
- xAction: 다음에 어떤 행동이 일어날지를 예측해 전개 패턴/문맥을 반영
- VAEP: 득점/실점 확률 변화 기반으로 행동 단위의 가치를 추정

1.2 목표 정의

본 프로젝트의 목표는 축구 경기 이벤트 데이터를 기반으로 한 행동 예측, 패스 성공 확률 추정, 그리고 행동 가치 평가를 단계적으로 수행하는 통합 분석 파이프라인을 구축하는 데 있다. 각 모듈은 서로 독립적인 예측 문제로 정의되지만, 최종적으로는 선수 및 팀 단위의 퍼포먼스 해석을 정량적으로 지원하도록 설계된다.

1.2.1 xAction

xAction 모듈의 목적은 경기 내 이벤트 흐름을 시계열로 모델링하여, 특정 시점에서 발생할 다음 액션의 유형을 예측하는 것이다.

입력은 단일 경기에서 시간 순으로 정렬된 이벤트 시퀀스이며, 각 이벤트는 Atomic SPADL 단위로 분해되며 위치, 시간, 액션 타입 등 기본적인 컨텍스트 정보를 포함한다.

출력은 다음에 발생할 액션의 type과 그 type에 속한 category로 정의된 다중 클래스 예측 문제이다.

축구 이벤트 데이터는 패스, 리시브와 같은 빈도가 높은 액션과 슛, 인터셉트 등 상대적으로 희귀한 액션 간의 클래스 불균형이 매우 크다. 이에 따라 전체 정확도보다는 각 클래스의 성능을 균등하게 반영할 수 있는 macro F1 score를 주요 평가 지표로 사용한다. 이를 통해 모델이 다수 클래스에 편향되지 않고, 다양한 행동 패턴을 얼마나 잘 학습했는지를 평가한다.

1.2.2 xPass

xPass 모듈은 개별 패스 시도의 성공 확률을 추정하는 확률 예측 문제로 정의된다.

입력은 특정 패스 이벤트와 함께 해당 패스가 발생하기 직전의 컨텍스트 정보로 구성되며, 이는 Atomic SPADL 단위로 분해된 이전 액션 시퀀스를 포함한다.

출력은 주어진 입력 조건 하에서 패스가 성공할 확률 $P(\text{complete} \mid x)$이다.

이 문제는 이진 분류이자 확률 추정 문제이므로, 단순 분류 정확도보다는 확률 예측의 품질을 평가할 수 있는 지표가 필요하다. 이에 따라 AUC-ROC를 통해 분류 경계의 전반적인 구분 능력을 평가하고, log loss 및 Brier score를 통해 예측 확률의 calibration 수준을 함께 평가한다. 이를 통해 모델이 성공·실패를 구분하는 능력뿐 아니라, 예측 확률이 실제 발생 빈도를 얼마나 잘 반영하는지를 검증한다.

1.3 난이도/도전 요소

- 불균형: 액션 타입 분포가 패스/인터셉트에 크게 편향
- 잡음/라벨 품질: 이벤트 매핑, 중복/결측, 품질 문제 레코드 존재
- 시계열성: 같은 경기 내 순서 정보가 핵심이며 누수 방지가 중요
- 고차원 혼합: 연속(좌표/변위/시간) + 범주(type/zone) 결합

2. 문제 정의

2.1 문제 유형과 타깃

- xAction: 다중 과제 분류
  - 타깃: next_type(다중 클래스), next_cat(다중 클래스)
- xPass: 이진 분류(확률 예측)
  - 타깃: pass completion(0/1)

3. 데이터셋 상세

3.1 출처 및 전처리

본 프로젝트에서 사용한 원천 데이터인 Wyscout에서 제공하는 이벤트 데이터는 실제 축구 경기에서 발생하는 주요 플레이를 시간 순으로 기록한 사건 기반 데이터로, 경기 및 선수 식별자, 발생 시점, 공간 좌표, 이벤트 유형과 결과, 그리고 신체 사용 부위나 패스 높이와 같은 세부 속성을 포함한다. 이러한 데이터는 경기 흐름을

정밀하게 재현할 수 있다는 장점이 있으나, 이벤트 정의와 분류 체계가 데이터 제공사 고유의 기준에 기반하고 있어 분석 목적에 따라 일관된 행동 단위로 활용하는 데에는 한계가 존재한다. 특히 하나의 이벤트가 여러 행동적 의미를 동시에 포함하는 경우가 많아, 모델 입력으로 직접 사용하기에는 구조적 복잡성이 따른다.

이를 보완하기 위해 본 프로젝트에서는 Wyscout 이벤트 데이터를 Atomic SPADL 포맷으로 전처리하였다. Atomic SPADL은 경기 중 발생하는 플레이를 의미적으로 분해 가능한 최소 단위의 원자적 행동으로 표현하는 데이터 구조로, 각 행동을 특정 시점에 수행된 단일 행위이자 경기 상태 변화의 기본 단위로 정의한다. 각 액션은 수행 주체와 공간적 위치, 그리고 행동 이후의 상태 전이를 포함하는 독립적인 분석 단위로 구성된다.

Atomic SPADL에서는 행동의 시작 위치와 공의 이동 변화를 함께 표현함으로써, 시간적으로 연속된 행동 간의 공간적 전이를 자연스럽게 모델링한다. 또한 패스, 슛과 같은 복합적인 플레이를 여러 개의 원자적 행동으로 분해하여 행동 시퀀스를 보다 세밀하게 구성함으로써, 다음 행동 예측과 VAEP 기반 가치 평가에서 개별 행동의 기여도를 정밀하게 분석할 수 있는 기반을 제공한다.

결측치와 이상치 처리는 Atomic SPADL 데이터의 구조적 특성을 유지하면서 모델 학습의 안정성을 확보하는 방향으로 수행되었다. 결측값이 존재하는 경우에는 해당 값을 제거하기보다는, 중립적인 기본값으로 대체하여 시퀀스의 연속성을 보존하였다. 이는 특정 행동의 일부 속성이 누락되었더라도 전체 시계열 구조가 붕괴되지 않도록 하기 위한 선택이다. 특히 공간 좌표나 행동 속성의 결측은 행동 자체의 부재로 해석하지 않고, 정보가 없는 상태로 간주하여 처리하였다.

이상치에 대해서는 통계적 제거보다는 범위 제한을 중심으로 한 보정 전략을 적용하였다. 필드의 물리적 범위를 벗어나는 좌표나 비현실적인 시간 간격은 사전에 정의된 합리적인 범위 내로 제한함으로써, 데이터 분포의 왜곡을 최소화하였다. 이러한 방식은 극단적인 값으로 인한 학습 불안정을 방지하는 동시에, 실제 경기 맥락에서 발생 가능한 행동 패턴은 최대한 유지하려는 목적을 가진다. 한편, 품질 분석 단계에서는 결측치와 이상치의 발생 빈도와 분포를 별도로 점검하여 데이터 전반의 신뢰도를 정성적으로 검증하였다.

종합하면, Atomic SPADL은 행동을 최소 단위로 분해한 고해상도 행동 표현이며, 본 프로젝트에서는 해당 구조를 유지한 상태에서 결측치와 이상치를 보수적으로 처리함으로써 시퀀스 모델링과 확률 기반 가치 평가에 적합한 입력 데이터를 구성하였다. 이는 데이터의 완전성보다는 행동 흐름의 연속성과 해석 가능성을 우선시한 전처리 전략으로 해석할 수 있다.

3.2 데이터 샘플링

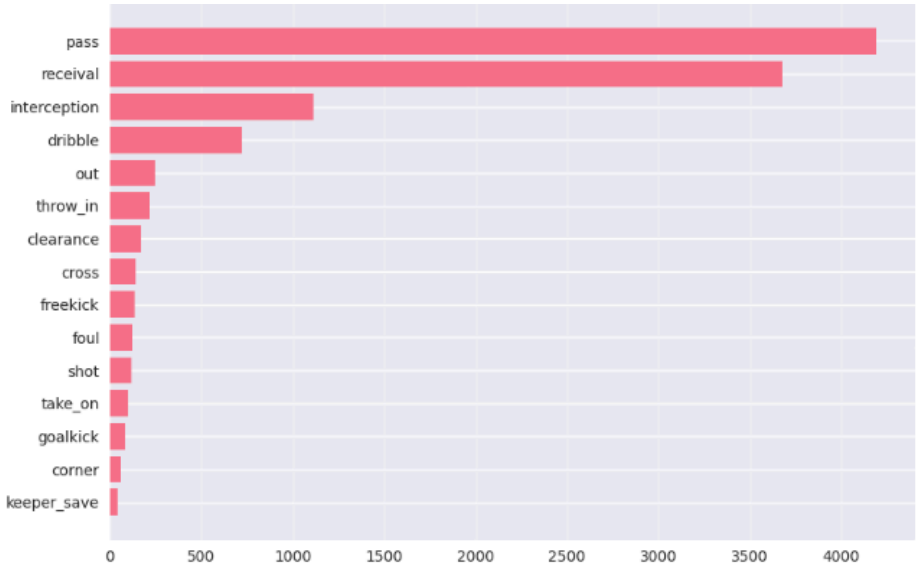
xAction 모듈은 경기 내 행동 흐름을 시계열 예측 문제로 정의한다. 하나의 표본은 단일 경기에서 시간 순으로 정렬된 이벤트 시퀀스로 구성되며, 고정 길이의 시퀀스 길이 (seq_len)을 기준으로 슬라이딩 윈도우 방식으로 생성된다. 각 시퀀스는 직전 (seq_len)개의 행동을 입력으로 사용하고, 그 다음에 발생하는 단일 행동의 type 및 category를 예측 대상으로 설정한다.

xPass 모듈은 개별 패스 행동을 독립적인 예측 단위로 간주한다. 하나의 표본은 패스 액션 1건에 해당하며, 해당 패스가 성공했는지 여부를 이진 변수(0/1)로 정의하여 예측한다.

3.3 데이터 규모

본 프로젝트에서 사용한 데이터셋은 총 4,367,255개의 행동 레코드로 구성되어 있으며, 이는 Atomic SPADL 기준으로 정의된 개별 액션 단위를 의미한다. 해당 데이터는 1,941경기의 실제 축구 경기로부터 추출되었으며, 총 142개 팀과 3,031명의 선수가 수행한 행동을 포괄한다.

3.5 데이터 편향/불균형



- 이벤트 타입 분포를 나타낸 count 그래프에 따르면, pass, 패스를 성공적으로 받은 receival, 그리고 패스가 상대에 의해 차단된 interception이 전체 이벤트의 약 75%를 차지하는 것으로 확인된다. 이는 본 프로젝트에서 사용한 행동 데이터가 공 소유의 전달과 그 결과로 발생하는 수령 또는 차단이라는 기본적인 경기 흐름에 의해 대부분 구성되어 있음을 의미하며, 데이터 구조상 패스 중심의 행동 편중이 뚜렷하게 존재함을 시사한다.

3.6 분할 방식

모델 학습과 성능 평가를 위해 전체 데이터셋은 학습(train), 검증(validation), 테스트(test) 세 부분으로 분할하였다. 각 분할의 비율은 70:15:15로 설정하였으며, 학습 데이터는 모델 파라미터 추정을 위해 사용되고, 검증 데이터는 하이퍼파라미터 조정 및 학습 과정에서의 과적합 여부를 점검하는 데 활용된다. 테스트 데이터는 학습 및 모델 선택 과정에 사용되지 않은 독립적인 데이터로 구성하여, 최종적으로 모델의 일반화 성능을 평가하는 기준으로 사용하였다.

4. 관련 연구

4.1 VAEP (Valuing Actions by Estimating Probabilities)

Valuing Actions by Estimating Probabilities (VAEP)은 개별 행동(action)이 경기 결과에 미치는 영향을 정량적으로 평가하기 위한 확률 기반 프레임워크이다. VAEP은 Tom Decroos, Lotte Bransen, Jan Van Haaren, Jesse Davis 등이 제안했으며, 2018년 KDD 및 이후 관련 논문에서 자세히 설명되었다. VAEP의 핵심은 행동 전후의 경기 상태가 득점 및 실점 가능성에 미치는 영향을 모델링하는 것이다. 각 행동은 그 행동이 경기 상태를 어떻게 변화시키는지에 따라 가치가 할당되며, 이는 다음과 같은 확률 차이로 정의된다:

- 행동 (a_i)는 상태 (S_{i-1})에서 (S_i)로 전이하며,
- 득점 가능성 ($P_{\text{scores}}(S, t)$) 및 실점 가능성 ($P_{\text{concedes}}(S, t)$)은 해당 상태에서 팀 ($t$)가 향후 짧은 시간 내에 득점 또는 실점할 확률을 의미한다.
- VAEP 값 ($V(a_i)$)은 다음과 같이 정의된다:

$$V(a_i) = \Delta P_{\text{scores}}(a_i) + (-\Delta P_{\text{concedes}}(a_i)),$$

즉, 행동 전후 득점 확률 변화량과 실점 확률 감소량의 합으로 해석된다. 이는 행동이 경기 흐름에 미친 순기여(net contribution)를 확률론적으로 평가하는 것으로, 득점·실점으로 직접 이어지지 않은 행동(예: 패스, 드리블)도 그 맥락적 가치가 정량화될 수 있게 한다. VAEP은 이벤트 데이터를 SPADL과 같은 표준 행동 언어로 변환한 뒤, 머신러닝 기반 확률 추정 모델을 통해 득점/실점 확률을 예측하고 행동 가치를 계산한다. 이 프레임워크을 통해 행동 가치는 선수, 경기, 시즌 수준으로 집계 가능하며, 이를 통해 선수의 전체적 경기 기여도를 비교하는 데 사용된다. VAEP은 2018년 및 2019년 이후 관련 연구에서 널리 인용되며, xT와 같은 다른 기대 기반 지표와 비교되는 주요 평가 체계로 자리잡았다.

4.2 xPass / Expected Pass Completion

Expected Pass Completion(xPass)은 패스 성공 확률을 맥락(context) 기반으로 추정하는 확률 예측 문제 정의이다. 패스는 경기 내 가장 빈번하게 발생하는 행동이지만, 전통적인 단순 성공률은 패스 난이도나 경기 상황을 반영하지 못한다는 한계가 있다. 이를 개선하기 위해 최근 연구는 위치, 거리, 방향, 선수 및 상대 선수의 공간적 배치 등 여러 맥락 변수를 입력으로 사용하여 패스가 성공할 확률을 머신러닝 분류 모델로 학습한다. 예를 들어 Gabriel Anzer 및 Pascal Bauer 등 (2022) 연구에서는 추적 데이터 기반으로 공 궤적 및 선수 움직임 정보를 결합한 모델을 통해 패스의 목표 방향 성공 여부 및 성공 확률을 추정하였다. 이 모델은 패스 성공/실패 확률을 출력하며, 출력된 확률 자체를 패스 난이도나 위험도(risk profile)로 해석할 수 있다. 확률 기반 패스 성공 예측은 선수 또는 팀의 패스 선택 경향과 성과를 정량화하고, 전술적 의사결정 분석에 활용될 수 있다.

4.3 xAction / Next-Event Prediction in Soccer

xAction 또는 Next-Event Prediction은 경기 데이터를 시계열(sequence)로 처리하여 과거 시퀀스 기반으로 다음에 발생할 행동 또는 이벤트의 유형과 속성을 예측하는 연구 영역이다. 이 문제는 자연어 처리에서의 시퀀스 예측과 유사하게, 과거 k개의 사건을 조건으로 다음 사건의 확률분포를 모델링한다. 전통적 접근은 Markov 모델 또는 순환신경망(RNN, LSTM, GRU)과 같은 시계열 모델을 사용하여 행동 전이 패턴을 학습하는 방법이었다. 최근에는 이러한 문제를 보다 일반화된 구조로 다루기 위해 Large Events Models(LEMs) 개념이 도입되고 있다. 2024년 연구에서는 LEMs가 경기 이벤트를 하나의 “token”으로 보고, 전체 문맥(context)을 고려해 다음 사건을 예측하는 딥러닝 기반 방법을 제안함으로써, 과거의 확률 기반 모델보다 높은 예측 정확도를 보이고 경기 시뮬레이션 및 분석 파이프라인 구축의 기반을 제공하고 있다. 이 접근은 행동 예측뿐만 아니라 경기 흐름 시뮬레이션, 전략 최적화 등에 응용될 수 있다.

5. 모델 상세

5.1 xAction: GRU/LSTM/Transformer

입력으로 주어진 과거 행동 시퀀스로부터 다음에 발생할 행동의 type과 category를 동시에 예측한다. 두 예측 문제는 상호 연관되어 있으나 별개의 분류 레이블 공간을 가지므로, 각각 독립적인 분류 헤드를 두고 학습한다.

- Head 1: 다음 행동의 action type (다중 클래스 분류)
- Head 2: 다음 행동의 action category (다중 클래스 분류)

이와 같은 구조는 행동의 구체적 type뿐 아니라 보다 상위 범주인 category까지 동시에 예측함으로써, 모델이 다중 수준의 행동 특성을 포착하도록 한다.

5.1.1 입력 표현

입력은 고정 길이의 과거 행동 시퀀스로 구성된다. 시퀀스 길이 seq_len은 모델 입력 창(window) 크기를 의미하며, 각 시퀀스는 시간 순으로 정렬된 행동 기록을 포함한다.

행동 하나는 다음과 같은 특징을 포함한다:

- Zone 기반 위치 표현

  경기장 평면 좌표는 연속값으로 처리하는 대신, 미리 정의된 격자(zone) 로 범주화한다.

  본 프로젝트에서는 12 × 8 격자 분할을 사용하여 zone_id를 생성함으로써 공간 정보를 고차원 위치보다 추상화된 범주로 표현한다.

- 수치형 피처

  행동 간 시간 차이, 상대 이동(dx, dy), normalized 위치 값 등의 수치형 피처가 포함된다.

- 공격 방향 정규화

  행동 시퀀스는 모든 입력이 동일한 공격 방향(왼쪽 → 오른쪽) 기준으로 정규화되어야 한다.

  공격 방향 정규화는 공간 패턴을 일관성 있게 모델링하기 위한 필수 전처리이며, 이를 적용하지 않을 경우 동일 행동이라도 방향 차이로 학습이 방해된다.

5.1.2 모델 아키텍처 (GRU, LSTM, Transformer)

본 연구에서는 세 가지 시퀀스 모델 구조를 동일한 입출력 스키마로 구현하여 비교 평가하였다:

- GRU (Gated Recurrent Unit)

  GRU는 순환 신경망(RNN)의 변형으로, 업데이트 게이트와 리셋 게이트를 통해 장기 의존성을 학습한다.

  GRU는 구조가 비교적 단순하여 계산 비용이 낮고, 짧은 시퀀스에서 빠른 수렴 및 안정적 학습이 가능하다.

- LSTM (Long Short-Term Memory)

  LSTM은 cell state와 입력/출력/포겟 게이트를 가진 순환 구조로, 장기 의존성 문제를 해결하도록 설계되었다.

  LSTM은 긴 시퀀스에서 중요한 과거 정보를 더 잘 유지하는 경향을 보이며, 복잡한 행동 전이 패턴 포착에 유리하다.

- Transformer

  Transformer는 attention 메커니즘에 기반한 시퀀스 모델로, 전통적인 순환 구조를 사용하지 않는다.

  Global attention을 통해 모든 시간 위치 간의 상호 작용을 동시에 고려할 수 있으며, 병렬 계산이 가능하여 대규모 데이터 학습에 적합하다.

세 모델 모두 동일한 feature embedding과 출력 헤드 구조를 공유하며, 모델 성능 비교를 통해 행동 예측 문제에 적합한 구조적 특성을 평가한다.

5.1.3 손실 함수 (Loss Function) 및 평가 지표

멀티태스크 구조에서 손실은 두 개의 분류 목표에 대해 가중 합으로 정의된다.

각 헤드는 별도의 Cross Entropy Loss를 적용하며, 전체 손실은 다음과 같다:



type 예측이 category 예측보다 더 높은 가중치를 가지도록 설계함으로써, 보다 세부적인 행동 유형 예측에 초점을 둔 학습이 이루어지며, 여기서 CE는 다중 클래스 Cross Entropy 손실을 의미한다.

Cross Entropy는 분류 문제에서 모델이 예측한 확률 분포가 실제 정답 분포와 얼마나 다른지를 측정하는 손실 함수이다. 확률 예측의 정확성과 신뢰도를 동시에 평가할 수 있다는 점에서, 다중 클래스 분류 문제에서 가장 널리 사용되는 기준이다.

다중 클래스 분류에서 실제 정답은 one-hot 벡터 y, 모델의 출력은 각 클래스에 대한 예측 확률 분포 $\hat{p}$ 로표현된다. 이때 Cross Entropy 손실은 다음과 같이 정의된다.

$$\mathcal{L}_{CE}(y, \hat{p}) = -\sum_{c=1}^{C} y_c \log(\hat{p}_c)$$

여기서 C는 클래스 수이며, 실제 정답 클래스에 해당하는 확률값의 로그에 음수를 취한 형태가 된다. 즉, 모델이 정답 클래스에 높은 확률을 할당할수록 손실은 작아지고, 낮은 확률을 할당할수록 손실은 급격히 증가한다.

평가 지표로는 클래스 불균형 특성을 고려하여 Macro F1 score를 주요 지표로 사용하였다. Macro F1은 각 클래스별 F1 score를 동일한 가중치로 평균한 값으로, 표본 수가 많은 다수 클래스에 의해 성능이 과도하게 좌우되는 문제를 완화한다. 특히 축구 행동 데이터와 같이 일부 행동 유형이 매우 낮은 빈도로 발생하는 환경에서는, 희귀 행동에 대한 예측 성능을 균형 있게 반영할 수 있다는 점에서 적합한 지표이다.

한편, Accuracy와 top-k accuracy는 보조 지표로 함께 활용하였다. Accuracy는 전체 예측 중 정답 비율을 통해 모델의 전반적인 분류 성능을 직관적으로 확인하는 데 사용되며, top-k accuracy는 모델이 상위 k개의 후보 중 하나로 정답 클래스를 포함하는지를 평가함으로써, 실제 활용 시의 유연한 예측 성능을 보완적으로 측정한다. 이러한 지표 조합을 통해 희귀 행동에 대한 민감도와 전체적인 예측 안정성을 함께 평가하고자 하였다.

5.1.4 학습 전략

- Early Stopping

  학습 과정에서 과적합을 방지하기 위해 Early Stopping을 적용하였다. 검증(validation) 세트에서의 val loss를 모니터링하여 개선이 일정 에폭(epoch) 동안 정체될 경우 학습을 중단한다.

- Optimizer

  본 연구에서는 옵티마이저로 AdamW를 사용하였다. AdamW는 Adam 옵티마이저에서 가중치 감쇠를 손실 함수의 정규화 항과 분리하여 적용하는 방식으로, 학습률 기반의 모멘트 추정과 가중치 감쇠를 독립적으로 제어할 수 있다. 이를 통해 과적합을 완화하고 일반화 성능을 안정적으로 유지할 수 있으며, 딥러닝 모델 학습에서 널리 사용되는 방법이다.

- 하이퍼파라미터 최적화

  하이퍼파라미터 튜닝은 TPE(Tree-structured Parzen Estimator) 기반의 베이지안 최적화 기법을 사용하였으며, Optuna 라이브러리를 통해 수행하였다. TPE는 기존의 그리드 서치나 랜덤 서치에 비해 탐색 효율이 높으며, 성능이 우수한 하이퍼파라미터 영역을 점진적으로 집중 탐색한다. 본 연구에서는 학습률, 은닉 차원 크기, 드롭아웃 비율 등의 주요 하이퍼파라미터를 탐색 대상으로 설정하였다.

- Gradient Clipping

  학습 과정에서 발생할 수 있는 그래디언트 폭주 문제를 방지하기 위해 gradient clipping을 적용하였다. 그래디언트의 노름이 사전에 설정한 임계값을 초과할 경우 이를 제한함으로써, 학습의 수치적 안정성을 확보하고 손실 함수의 발산을 방지하였다. 이는 순환 신경망 계열 및 시계열 모델 학습에서 특히 중요한 안정화 기법이다.

5.2 xPass: XGBoost

xPass 모듈은 개별 패스 시도의 성공 확률 $P(complete|x)$ 을 추정하는 확률 예측 문제로 정의된다. 이는 이진 분류(Binary Classification) 문제이지만, 단순한 성공/실패 분류를 넘어 의사결정의 난이도와 품질을 반영하기 위해 확률값 추정이 핵심이 된다.

5.2.1 입력 표현

입력은 개별 패스 이벤트와 해당 시점의 컨텍스트 정보로 구성된다. 시계열 시퀀스를 입력으로 받는 nextAction과 달리, xPass는 해당 패스의 성공 여부를 결정짓는 물리적·상황적 요인을 포착하는 데 집중한다

- 기하/공간 피처 (Geometric/Spatial Features): 패스의 시작 및 종료 좌표, 패스 거리, 각도, 골대 방향으로의 전진성 등 패스 자체의 물리적 난이도를 나타내는 수치형 정보가 포함된다.
- 컨텍스트 피처 (Context Features): 단일 이벤트의 정보 부족을 보완하기 위해, 직전 이벤트(prev_event)의 유형과 같은 이전 액션 정보를 일부 포함하여 상황적 맥락을 반영한다.

5.2.2 모델 아키텍처

본 프로젝트에서는 정형(tabular) 데이터 분류 문제에서 우수한 성능과 안정성을 보이는 XGBoost(Extreme Gradient Boosting) 알고리즘을 사용하였다. XGBoost는 결정트리 기반의 앙상블 기법으로, 비선형 관계와 변수 간 상호작용을 효과적으로 학습할 수 있으며, 과적합 제어와 계산 효율성 측면에서 장점을 가진다.

본 프로젝트에서는 XGBClassifier를 사용하였으며, 목적 함수(objective)는 binary:logistic으로 설정하였다. 이를 통해 모델은 이진 클래스에 대해 0과 1 사이의 확률값을 출력하도록 설계되었으며, 해당 확률은 이후 VAEP 및 확률 기반 분석에서 직접 활용 가능하도록 구성하였다.

5.2.3 손실 함수 및 평가 지표

본 프로젝트의 xPass 데이터셋은 패스 성공률(Positive Rate)이 약 85%에 달하는 고도로 불균형한 분포를 보인다. 이러한 환경에서는 단순히 성공/실패를 맞추는 '정확도(Accuracy)'나 순위 기반의 'AUC-ROC'만으로는 모델의 실질적인 성능을 온전히 평가하기 어렵다. 따라서 본 연구에서는 모델의 분별력뿐만 아니라 예측된 확률의 정합성과 보정 수준을 입체적으로 검증하기 위해 AUC, LogLoss, Brier Score를 복합적으로 활용하였다.

- AUC-ROC (Area Under the Receiver Operating Characteristic Curve)

  정의 및 수식: AUC는 모델이 임의의 성공 케이스(1)에 임의의 실패 케이스(0)보다 더 높은 확률을 부여할 확률을 의미하며, 클래스 간의 순위(Rank)를 얼마나 잘 매기는지를 나타내는 척도이다.

  $$\mathrm{AUC} = P(\hat{p}_{\mathrm{pos}} > \hat{p}_{\mathrm{neg}})$$

  선정 근거: 패스 성공 확률 예측에서 가장 기본적인 요구사항은 "성공할 패스를 실패할 패스보다 더 높은 확률로 예측하는 것"이다. AUC는 확률 값의 절대적 크기와 무관하게, 모델의 분별력 자체를 평가하기 위해 사용된다.

- Log Loss (Logarithmic Loss / Cross-Entropy)

  정의 및 수식: Log Loss는 예측 확률 분포와 실제 레이블 분포 사이의 정보 이론적 거리를 측정하며, 모델이 예측한 확률에 대해 틀렸을 경우 그 확신(Confidence)의 정도만큼 페널티를 부여한다.

  $$\mathrm{LogLoss} = -\frac{1}{N}\sum_{i=1}^{N}[y_i \log(\hat{p}_i) + (1-y_i)\log(1-\hat{p}_i)]$$

선정 근거: 성공률이 85%인 데이터에서 모델이 무조건 성공(1.0)이라고 과신하거나, 반대로 애매한 확률(0.5)로 회피하는 것을 방지해야 한다. Log Loss는 모델이 정답을 맞추는 것을 넘어, 예측 확신도가 얼마나 적절한지를 검증하는 데 필수적이다.

- Brier Score

  정의 및 수식:Brier Score는 예측된 확률값과 실제 결과값 간의 평균제곱오차(MSE)로 정의되며, 확률 값 자체의 정확도를 물리적으로 측정한다.

$$\text{Brier Score} = \frac{1}{N}\sum_{i=1}^{N}(\hat{p}_i - y_i)^2$$

  선정 근거 (Rationale):
  xPass는 최종적으로 VAEP와 같은 기댓값 계산에 활용되므로, 예측된 확률이 실제 발생 빈도와 일치하는 확률 보정(Calibration) 능력이 중요하다. 예를 들어, 모델이 0.8로 예측한 패스들은 실제 80%가 성공해야 한다. Brier Score는 이러한 확률의 신뢰성을 평가하는 가장 직관적인 지표이다.

5.2.4 학습 전략

과적합 방지와 최적 성능 도출을 위해 Optuna(TPE)를 활용한 하이퍼파라미터 탐색과 2-Stage 학습 프로세스를 적용하였다.

1. Stage 1 (탐색): Train/Val 분할 데이터에서 Early Stopping(rounds=100)을 적용하여 검증 셋의 Log Loss가 최소화되는 최적의 best_iteration과 하이퍼파라미터를 탐색한다.
2. Stage 2 (재학습): 탐색된 최적 설정과 반복 횟수를 바탕으로 Train과 Validation 데이터를 병합하여 전체 데이터로 최종 모델을 재학습한다.

6. 결과 및 분석

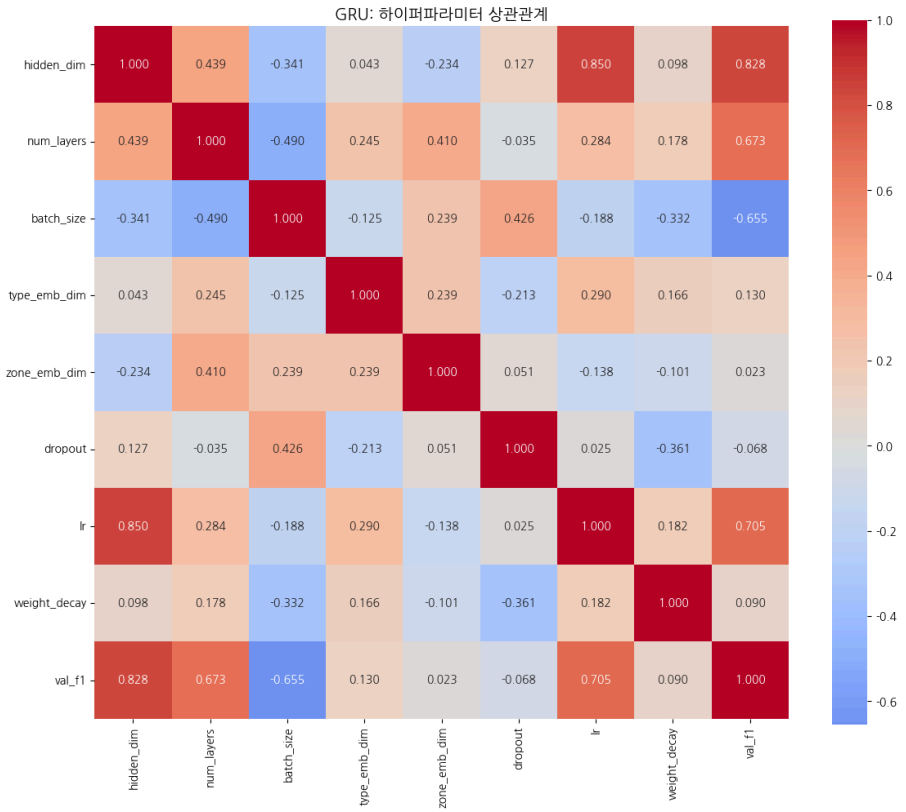
6.1 xAction

6.1.1 하이퍼파라미터 분석

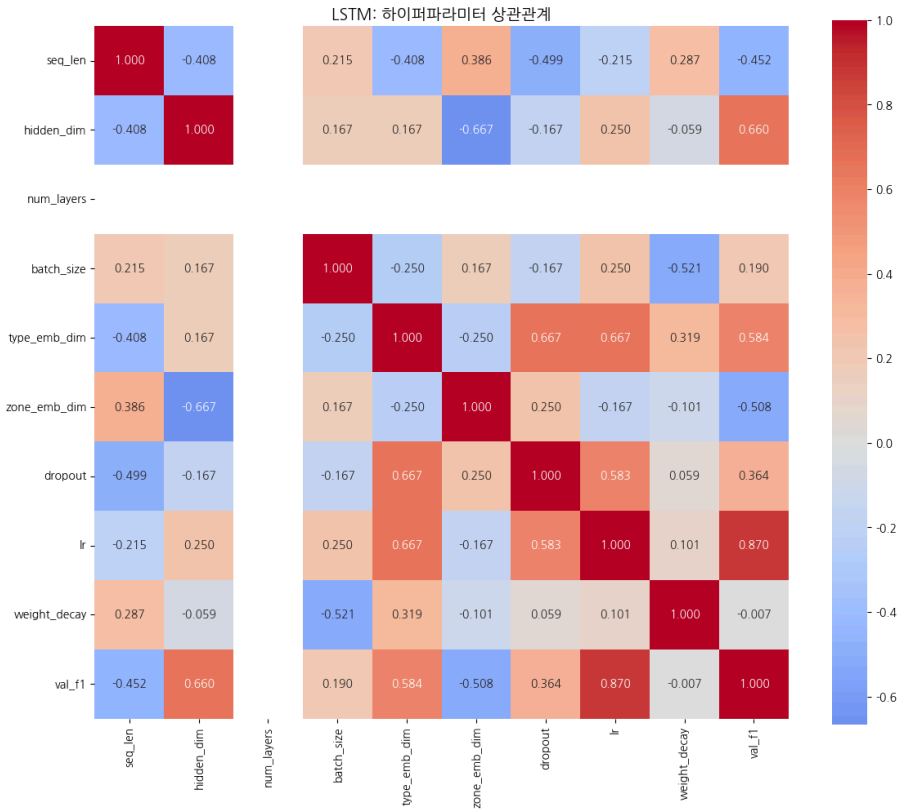
초기 단계에서는 하이퍼파라미터 공간 전반을 탐색하기 위해 **randomized search**를 우선적으로 수행하였다. 이 과정은 사전 가정 없이 넓은 범위의 하이퍼파라미터 조합을 샘플링함으로써, 모델 성능에 민감하게 작용하는 주요 파라미터와 대략적인 유효 범위를 식별하는 것을 목적으로 한다. 랜덤 탐색 결과, 특정 하이퍼파라미터 구간에서 상대적으로 안정적이거나 우수한 성능이 반복적으로 관측되었으며, 반대로 성능에 기여도가 낮은 영역 또한 확인되었다.

이러한 초기 탐색 결과를 바탕으로, 후속 단계에서는 탐색 공간을 보다 축소·정제된 범위로 재정의하였다. 이후 하이퍼파라미터 간의 조건부 의존성과 성능 분포를 효율적으로 활용할 수 있는 Tree-structured Parzen Estimator(TPE) 기반 탐색을 적용하여, 제한된 계산 자원 내에서 보다 정밀한 최적화를 수행하였다. 이와 같은 2단계 탐색 전략은 무작위 탐색을 통해 전역적인 구조를 파악한 뒤, 확률적 모델을 활용해 유망한 영역을 집중적으로 탐색함으로써 하이퍼파라미터 최적화의 효율성과 안정성을 동시에 확보하기 위한 접근이다.

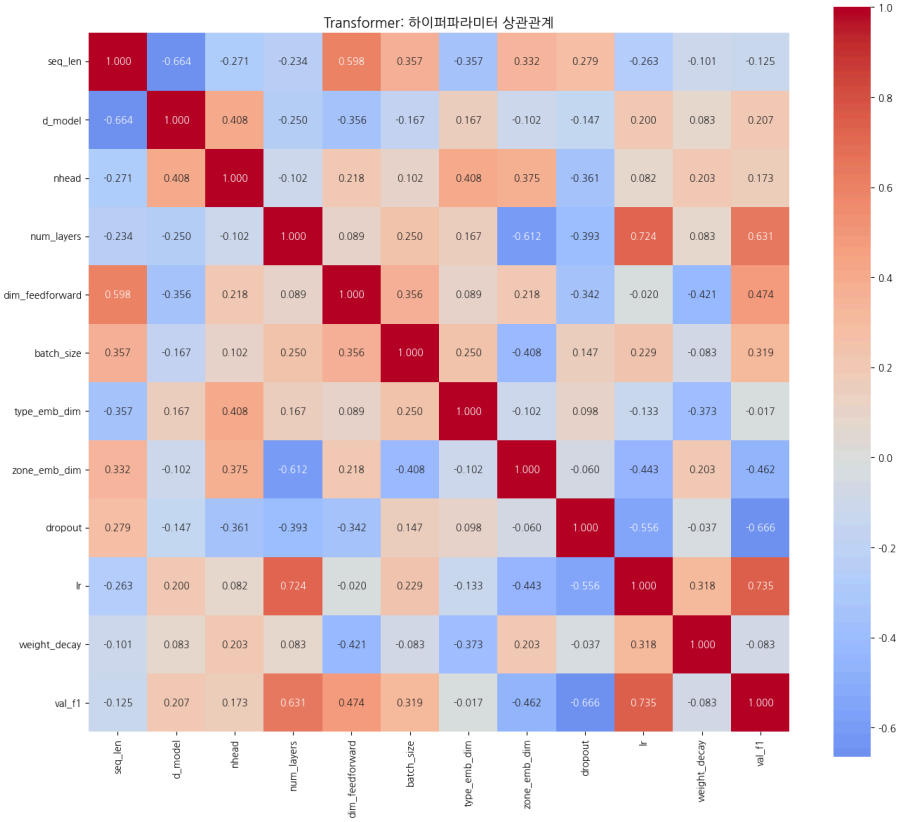
또한 TPE는 관측된 실험 결과를 바탕으로 성능이 우수한 하이퍼파라미터 조합에 더 높은 확률을 할당하여 다음 탐색 후보를 선택하는 방식이므로, 하이퍼파라미터 간의 독립적인 상관관계를 사후적으로 분석하는 절차는 별도로 수행하지 않았다. 본 프로젝트에서는 TPE 자체가 성능 분포를 근거로 탐색 방향을 점진적으로 편향시키는 확률적 모델이라는 점을 고려하여, 개별 하이퍼파라미터의 단변량 또는 쌍변량 상관 분석보다는 최종적으로 도출된 조합의 성능을 기준으로 모델을 선택하는 데 초점을 두었다.



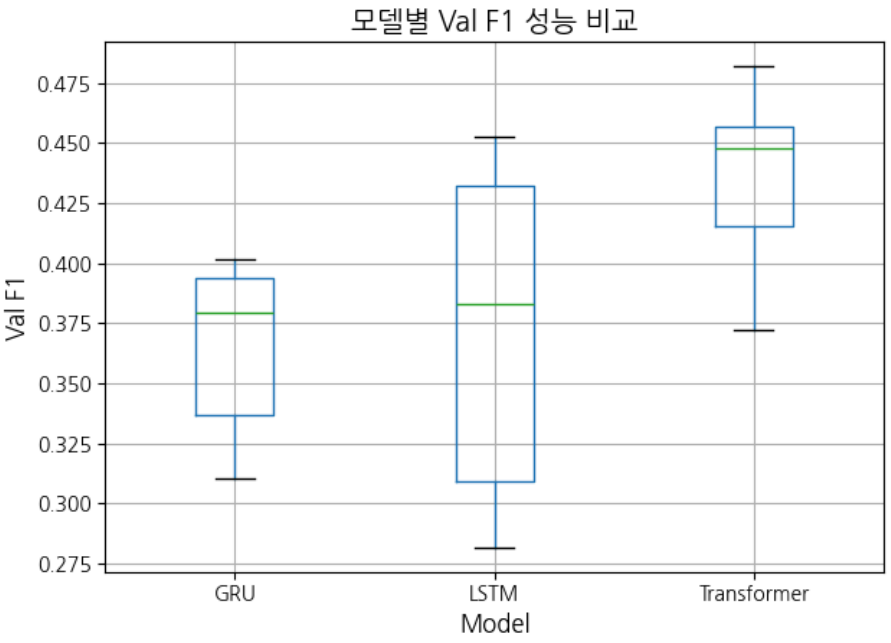
- GRU 모델에서 검증 성능(val F1)과의 상관관계를 보면, hidden_dim이 가장 높은 양의 상관계수(0.83)를 보여 성능에 가장 큰 영향을 미쳤다. 학습률(lr)과 레이어 수(num_layers) 역시 각각 0.71, 0.67의 양의 상관관계를 나타내며, 최적화 설정과 모델 깊이가 중요한 요인임을 시사한다. 반면 type_emb_dim(0.13), weight_decay(0.09), zone_emb_dim(0.02)은 상관계수가 매우 낮아 성능 영향이 제한적이었다. dropout은 약한 음의 상관관계(−0.07)를 보였고, batch_size는 비교적 강한 음의 상관관계(−0.65)를 나타내어 작은 배치 크기가 val F1에 유리했음을 보여준다.



- LSTM의 경우, val F1과 가장 높은 상관관계는 학습률(lr)로 0.87을 보였으며, 최적화 설정이 성능에 가장 결정적인 영향을 미쳤다. 그 다음으로 hidden_dim(0.66)과 type_emb_dim(0.58)이 비교적 높은 양의 상관관계를 나타내어, 모델 용량과 타입 임베딩 표현력이 성능에 기여했음을 시사한다. dropout은 0.36으로 완만한 양의 상관관계를 보였으나, seq_len(−0.45)과 zone_emb_dim(−0.51)은 음의 상관관계를 보여 긴 시퀀스나 과도한 공간 임베딩이 오히려 성능을 저하시켰다. weight_decay는 거의 0(−0.01)으로 영향이 미미했으며, num_layers는 실험 변동이 없어 상관계수를 산출할 수 없었다.



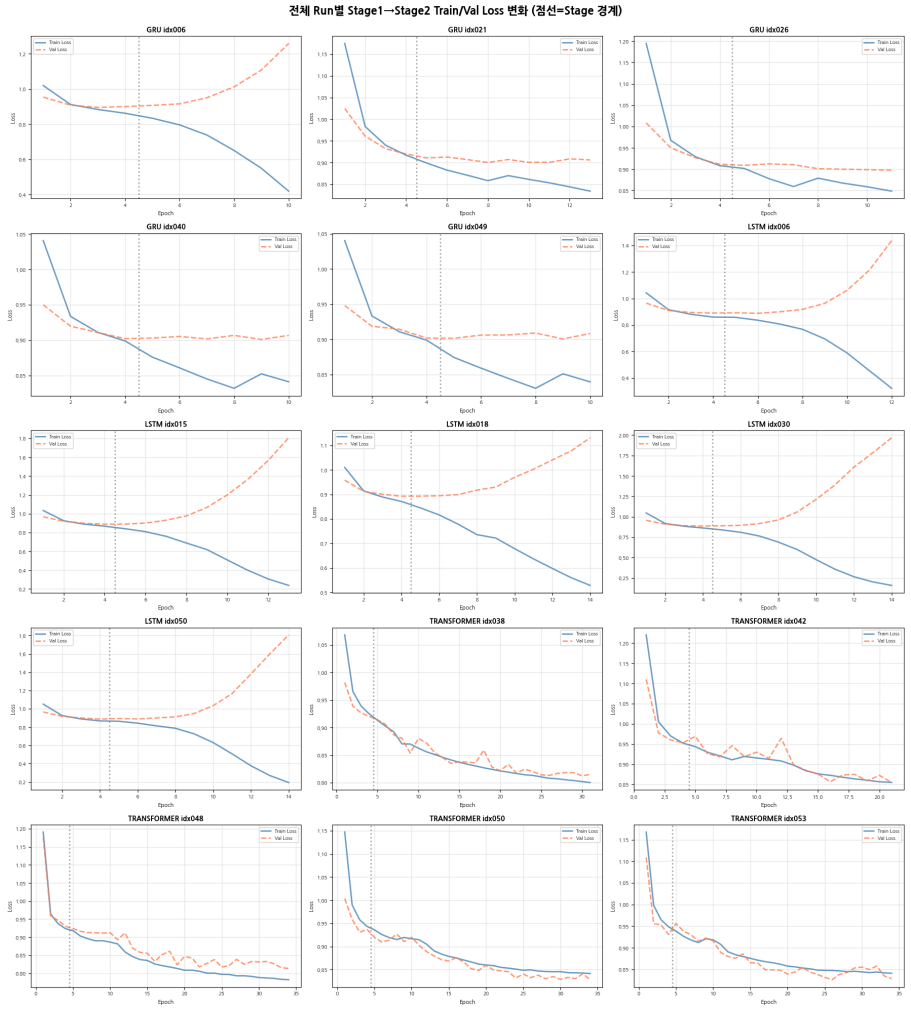
- Transformer의 경우에도 학습률(lr)이 가장 높은 양의 상관계수(0.73)를 보여 성능에 핵심적인 요소임을 확인할 수 있다. 이어서 num_layers(0.63)와 dim_feedforward(0.47)가 비교적 높은 양의 상관관계를 나타내어, 모델 깊이와 FFN 차원이 성능에 중요한 역할을 했음을 시사한다. 반면 dropout은 −0.67로 강한 음의 상관관계를 보여, 과도한 정규화가 Transformer 성능을 크게 저하시켰다. 또한 zone_emb_dim은 −0.46으로 음의 상관관계를 보였고, seq_len 역시 약한 음의 상관관계(−0.13)를 나타냈다. type_emb_dim과 weight_decay는 상관계수가 거의 0에 가까워 성능 영향이 제한적이었다.



- 초기 randomized search 단계에서 모델별 검증 성능(val F1)을 비교한 결과, Transformer가 0.482로 가장 높은 성능을 보였으며, 그 다음으로 LSTM이 0.453, GRU가 0.402의 순으로 나타났다. 이는 동일한 입력 표현과 학습 설정 하에서, 자기 주의 메커니즘을 활용하는 Transformer가 순환 구조 기반 모델보다 행동 시퀀스의 복잡한 전이 패턴을 보다 효과적으로 포착했음을 시사한다.

6.1.2 xAction 모델 성능 분석

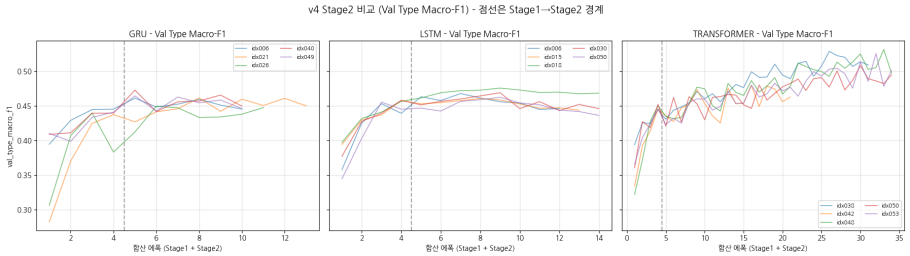
앞선 randomized search 이후, 각 모델(GRU, LSTM, Transformer)에 대해 TPE 기반 하이퍼파라미터 탐색을 각각 50회(trial) 수행하였다. 탐색 효율을 높이기 위해 2-stage 학습 전략을 적용하였다. 1단계에서는 전체 데이터셋의 50%만 사용하여 최대 5에폭까지 빠른 사전 평가를 수행하였고, 이를 통해 성능이 우수한 설정을 선별하였다. 이후 2단계에서는 1단계 결과를 기준으로 상위 5개 하이퍼파라미터 조합을 선택하여 전체 데이터셋을 사용한 본 학습을 진행하였다. 이 단계에서는 최대 30에폭까지 학습을 수행하였으며, 검증 손실(val loss)이 6에폭 연속으로 개선되지 않을 경우 조기 종료(early stopping) 를 적용하여 과적합을 방지하였다.



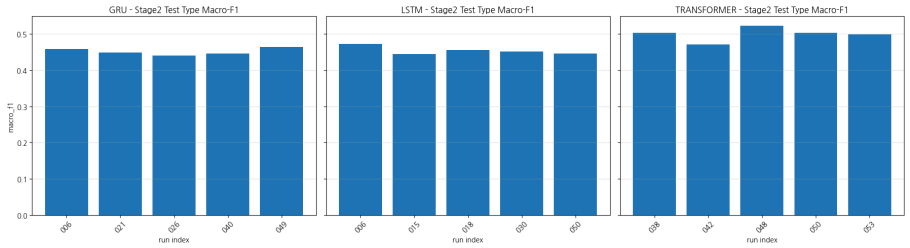
- GRU의 경우 학습 초기에 train loss가 일시적으로 상승하는 구간이 관찰되었으나, 전체 학습 과정에서는 점진적으로 감소하는 경향을 보여 모델이 정상적으로 수렴했음을 확인할 수 있다. 검증 손실(val loss)은 전반적으로 비교적 안정적인 수준을 유지하여 과도한 과적합 징후는 나타나지 않았다.

  반면 LSTM은 학습이 진행될수록 train loss와 val loss 간의 격차가 크게 확대되는 양상을 보였으며, 이는 모델이 학습 데이터에 과적합되는 경향을 보였음을 시사한다. 이에 비해 Transformer는 학습 과정 전

반에서 train loss와 val loss가 함께 감소하는 추세를 보여, 상대적으로 안정적인 일반화 성능을 유지하며 학습이 진행되었음을 확인할 수 있다.



- 클래스 불균형을 고려한 macro F1 score를 기준으로 살펴보면, GRU와 LSTM은 학습이 진행되더라도 성능이 크게 향상되는 양상을 보이지 않았다. 반면 Transformer는 학습이 진행됨에 따라 macro F1이 꾸준히 상승하는 경향을 보여, 희귀 행동을 포함한 전반적인 클래스 예측 성능이 지속적으로 개선되었음을 확인할 수 있다.



2-stage TPE 탐색 결과를 기준으로 모델별 상위5개 모델의 성능 변화를 비교하면, Transformer가 가장 큰 성능 향상과 최고 성능을 기록하였다.

GRU의 경우 Stage1 Test F1은 0.4265에서 Stage2에서 0.4646으로 증가하여 **0.0382의 향상**을 보였다. 은닉 차원(hidden_dim=1536)과 비교적 깊은 구조(num_layers=3)를 사용했으나, 성능 개선 폭은 제한적이었다.

LSTM은 Stage1 Test F1 0.4552에서 Stage2 0.4726으로 0.0174의 소폭 향상에 그쳤다. GRU와 유사한 은닉 차원을 사용했음에도 불구하고, 전체 데이터셋 학습으로 인한 추가 성능 이득은 상대적으로 작았다.

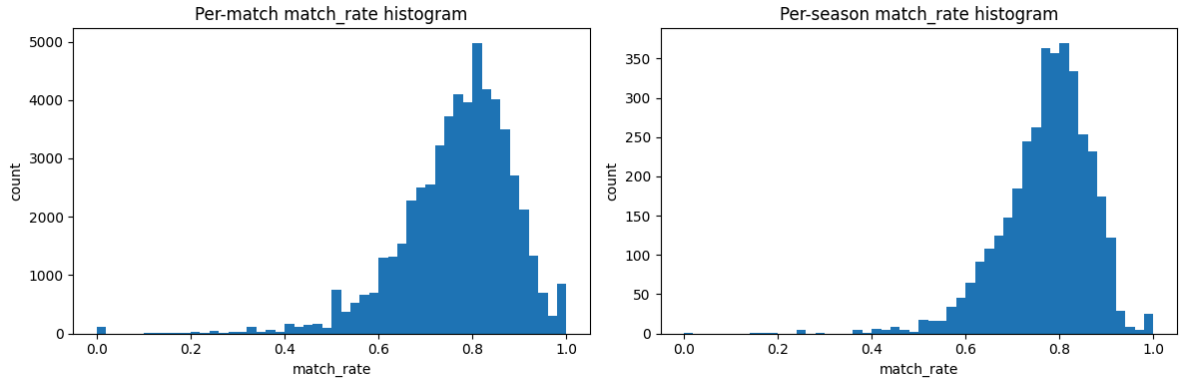
반면 Transformer는 Stage1 Test F1 0.4456에서 Stage2에서 0.5228로 상승하여 0.0772의 가장 큰 향상 폭을 보였다. 상대적으로 짧은 시퀀스 길이(seq_len=4)와 깊은 인코더 구조(num_layers=7), 충분한 feedforward 차원(dim_feedforward=1536)을 사용한 설정에서 성능이 크게 개선되었으며, 이는 Transformer가 행동 시퀀스의 전역적 의존성을 효과적으로 학습했음을 시사한다.

또한 본 프로젝트에서 사용한 성능 지표는 클래스 불균형을 고려한 macro F1 score로, 이는 각 행동 타입을 동일한 가중치로 평가하기 때문에 단순 정확도 대비 훨씬 엄격한 기준에 해당한다. 실제 xAction 문제는 총 23개 행동 클래스로 구성되어 있으며, 테스트셋 라벨 분포 또한 강한 불균형을 보인다. 이 설정에서 각 클래스를 균등 확률로 무작위 예측하는 이론적 랜덤 베이스라인의 기대 macro F1은 약 0.0206 수준에 불과하다(기대 정확도는 약 0.0435).

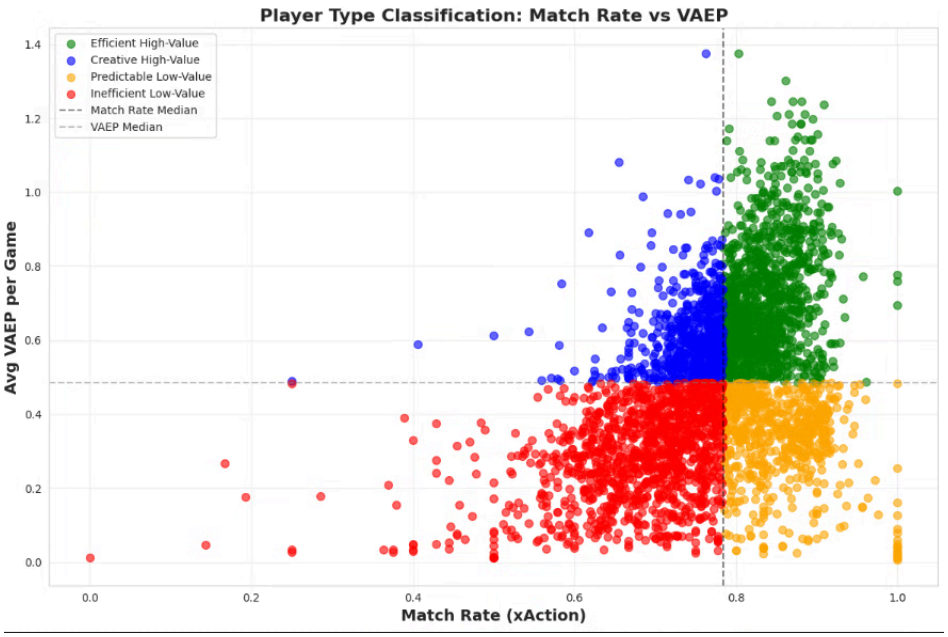
이와 비교할 때, Transformer 모델이 Stage2에서 기록한 Test macro F1 = 0.5228은 랜덤 베이스라인 대비 약 25배 이상 높은 성능으로, 단순한 클래스 빈도 학습이나 우연적 예측이 아닌 행동 시퀀스의 구조적 패턴과 전이 관계를 효과적으로 학습했음을 명확히 보여준다. 특히 macro F1 기준에서 이러한 격차는 희귀 행동 타입에 대해서도 의미 있는 예측 성능을 확보했음을 의미하며, 본 모델이 실질적인 행동 예측 문제를 해결하는 데 충분한 표현력과 일반화 성능을 갖추었음을 뒷받침한다.

6.1.3 xAction Residual

xAction 예측 결과와 실제 선수가 수행한 행동을 비교하여, 행동 일치율과 불일치 상황에서의 행동 유형 분포를 분석하고, 이 지표들과 VAEP 값 간의 상관관계를 함께 검토하였다. 이를 통해 특정 선수가 평균적인 행동 패턴을 따르는지 여부를 정량적으로 평가하고, 만약 일반적인 예측과 다른 행동을 수행하는 경우 해당 행동들이 실제로 더 높은 VAEP 값을 수반하는지를 분석하였다. 이러한 분석은 예측된 표준 행동과의 괴리를 기준으로, 선수가 관행적인 플레이를 수행하는지 혹은 상대적으로 비정형적이지만 가치가 높은 행동을 선택하는지를 구분하는 데 목적이 있다.



- 행동 일치율 분포를 살펴보면, 대부분의 선수들이 약 0.8 수준의 일치율 구간에 밀집되어 있는 것으로 나타난다. 이는 다수의 선수가 평균적인 경기 맥락에서 예측 가능한 표준적 행동 패턴을 주로 수행하고 있음을 시사한다.



행동 예측 일치율(match_rate) 과 VAEP 중앙값(median VAEP) 을 기준으로 선수들을 이차원 공간에 배치한 결과, 선수 유형은 네 가지 범주로 구분될 수 있었다. 구분 기준은 일치율의 높고 낮음과, VAEP 중앙값의 높고 낮음의 조합으로 정의된다.

먼저 Efficient High-Value (green) 그룹은 행동 예측 일치율이 높고 VAEP 중앙값 또한 높은 선수들로 구성된다. 이들은 모델이 예측한 일반적인 행동 패턴을 안정적으로 수행하면서도, 각 행동이 평균적으로 높은 가치를 창출하는 유형으로, 효율성과 안정성을 동시에 갖춘 선수로 해석할 수 있다.

Creative High-Value (blue) 그룹은 행동 예측 일치율은 낮지만 VAEP 중앙값이 높은 선수들이다. 이들은 예측 모델이 기대하는 표준 행동과는 다른 선택을 자주 수행하지만, 그 결과가 실제 경기에서는 높은 득실 기대값으로 이어지는 경우가 많다. 즉, 비정형적이지만 창의적이며 고가치의 플레이를 만들어내는 선수 유형이다.

반대로 Predictable Low-Value (orange) 그룹은 행동 예측 일치율은 높으나 VAEP 중앙값이 낮은 선수들로, 예측 가능한 행동을 수행하지만 그 기여도가 상대적으로 제한적인 유형에 해당한다. 이는 안정적인 역할 수행은 가능하나, 경기의 기대 득실을 크게 변화시키지 않는 플레이 스타일로 해석할 수 있다.

마지막으로 Inefficient Low-Value (red) 그룹은 행동 예측 일치율과 VAEP 중앙값이 모두 낮은 선수들로 구성된다. 이들은 예측 모델이 기대하는 행동에서도 벗어나면서 동시에 행동의 가치 역시 낮아, 비효율적인 선택이 반복되는 유형으로 해석된다.

여기서 비정형 고가치 선수(Creative High-Value Players)들에 주목해서 추가로 분석해보면 아래와 같은 Creative High-Value Top 5 선수 목록과 주요 지표를 얻을 수 있다

순위	선수	match_rate	mismatch_rate	경기 수(n_total)	VAEP/90
1	Neymar	0.762	0.238	703	1.175
2	L. Insigne	0.655	0.345	58	1.082
3	L. Messi	0.773	0.227	520	1.040
4	K. Walker	0.779	0.221	393	1.037
5	A. Kolarov	0.740	0.260	312	1.035

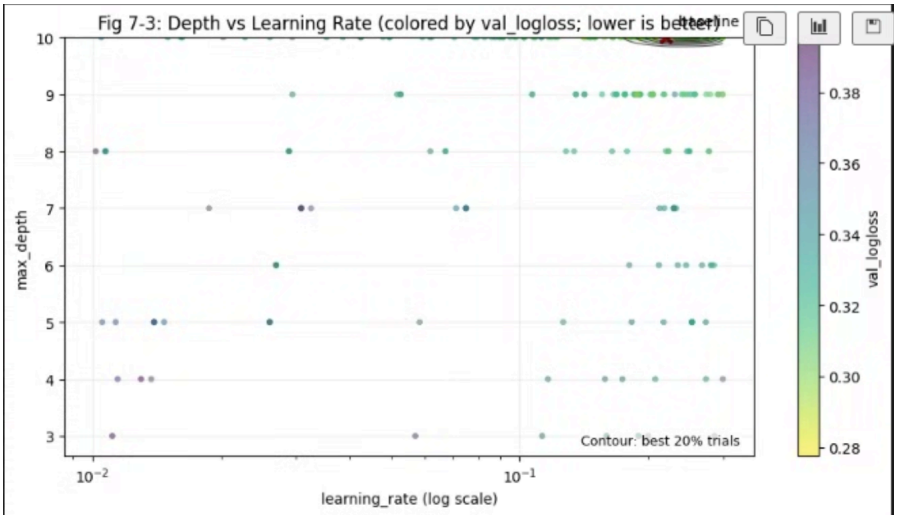
이 선수들은 데이터 수집 시점인 2017년 기준, 유럽 최상위 리그의 최고 수준 클럽에 소속되어 있었으며, 당시 최고수준의 시장가치와 경기 영향력을 인정받고 커리어의 정점 또는 전성기를 형성하던 선수들이다. 이러한 사실은 낮은 행동 일치율에도 불구하고 높은 VAEP을 기록한 결과가 우연이나 데이터 편향이 아니라, 실제 축구 맥락에서 검증된 선수들의 창의적 의사결정 특성을 반영하고 있음을 뒷받침한다. 따라서 본 분석은 비정형적 행동이 단순한 예측 실패가 아니라, 고가치 플레이로 이어질 수 있는 선수 고유의 경쟁력임을 실증적으로 보여주는 근거로 해석할 수 있다.

6.2 xPass 성능

6.2.1 하이퍼파라미터 분석

xPass 모델의 하이퍼파라미터 튜닝은 Optuna의 TPE(Tree-structured Parzen Estimator) 기반 베이지안 최적화를 통해 수행되었으며, 최적화의 목적 함수(Objective)는 검증 데이터셋(Validation)의 LogLoss 최소화로 설정하였다. 이는 단순 분류 정확도가 아닌, 패스 성공 확률의 확률적 정합성과 신뢰도를 직접적으로 개선하는 것을 목표로 한 선택이다.

- max_depth (트리 깊이): 트리의 깊이가 증가할수록 위치, 거리, 상황 변수 간의 복잡한 비선형 상호작용을 보다 정교하게 학습할 수 있다. 그러나 일정 깊이를 초과할 경우 학습 데이터에 과도하게 적합되어 일반화 성능이 급격히 저하되는 오버피팅 위험이 증가하는 경향이 관찰되었다.



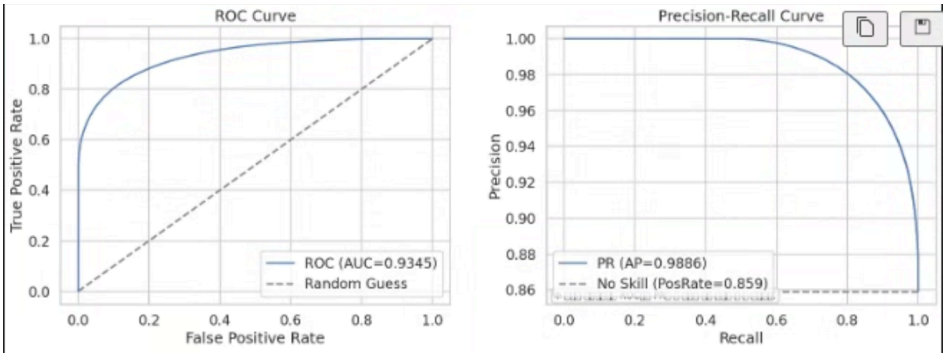
- learning_rate (학습률): 모델의 수렴 속도와 학습 안정성을 결정하는 핵심 파라미터이다. 트리 깊이가 깊을수록 각 분기의 영향력이 커지므로, 상대적으로 더 작은 학습률이나 강한 규제가 요구되는 상관관계가 나타났다. 이는 과도한 확률 편향을 방지하고 안정적인 LogLoss 감소를 유도하는 데 중요한 역할을 한다.
- min_child_weight: 리프 노드에 포함되는 최소 가중치 합을 제한함으로써, 표본 수가 극히 적은 분할로 생성되는 불안정한 노드를 억제한다. 이 파라미터는 max_depth 및 learning_rate와 상호작용하며, 과도하게 세분화된 트리 구조를 방지함으로써 모델의 과적합을 완화하고 일반화 성능을 확보하는 데 기여한다.

6.2.2 xPass 모델 성능 분석

최종 모델 학습에는 2-Stage 전략을 적용하였다. Stage 1에서는 Early Stopping을 통해 검증 성능 기준의 최적 반복 횟수(Iteration)를 탐색하고, Stage 2에서는 Train과 Validation 데이터를 병합하여 재학습함으로써 데이터 활용도를 극대화하고 일반화 성능을 확보하였다.

최종 성능 평가 결과는 아래 표와 같다.

Split	AUC-ROC	LogLoss	Brier	N	Pos rate
Train	0.9904	0.1735	0.0516	2,360,250	0.8538
Val	0.9900	0.1776	0.0532	584,241	0.8508
Test	0.9759	0.1997	0.0614	743,274	0.8549



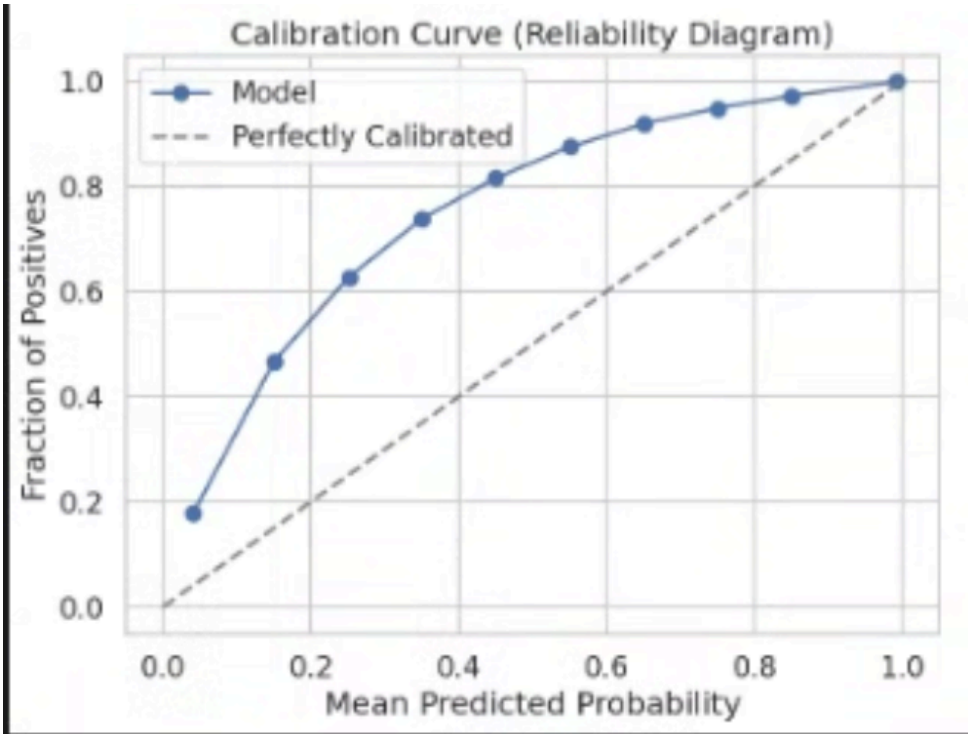
첫째, 분별력(discrimination) 측면에서 xPass 모델은 Test 기준 AUC-ROC 0.9759를 기록하여, 패스 성공과 실패를 매우 높은 정확도로 구분하는 능력을 보였다. 이는 다양한 경기 맥락 변수들이 패스 결과 판별에 효과적으로 활용되었음을 의미한다.

둘째, 확률 예측 품질(calibration) 측면에서 Test 기준 LogLoss 0.1997과 Brier Score 0.0614의 낮은 값을 기록하였다. 이는 데이터가 성공 패스에 편향된 불균형 환경임에도 불구하고, 모델이 단순히 다수 클래스에 확신을 쏠리는 것이 아니라 상황별 실패 위험을 적절히 반영한 확률 출력을 생성하고 있음을 시사한다.

셋째, 일반화 성능(generalization) 측면에서 Train LogLoss(0.1735)와 Test LogLoss(0.1997)의 차이가 약 0.0262로 제한적으로 유지되었다. 이는 학습 데이터에 대한 과도한 적합 없이, 보지 않은 데이터에서도 안정적인 성능을 유지하고 있음을 보여준다.

6.2.3 예측 정합성 및 분포 분석

xPass 데이터의 Test Positive Rate는 0.8549로, 성공 패스가 지배적인 강한 클래스 불균형 분포를 보인다. 이러한 환경에서는 단순 정확도(Accuracy)가 다수 클래스 예측만으로도 쉽게 높아질 수 있어, 모델 성능을 평가하는 지표로서의 효용이 제한적이다. 따라서 본 프로젝트에서는 정확도 대신, 각 상황에서의 패스 성공 확률을 얼마나 정교하고 일관되게 추정하는지, 즉 확률 예측의 보정 정도(calibration) 를 중심으로 모델의 품질을 평가하였다.



지표 기반 해석:

Brier Score (0.0614)는 예측 확률과 실제 결과값(0 또는 1) 간의 평균 제곱 오차가 매우 낮음을 의미하며, 모델이 출력한 확률 분포가 실제 패스 성공 빈도와 정합적으로 정렬되어 있음을 보여준다. 이는 확률 예측의 보정(calibration) 품질이 우수함을 시사한다.

LogLoss (0.1997*는 오분류된 사례에 대해 높은 확신을 부여할수록 큰 페널티를 부과하는 지표이다. 낮은 LogLoss 값은 모델이 다수 클래스인 '성공'에 과도하게 확률을 집중시키는 과신(overconfidence) 현상을 보이지 않고, 상황별 실패 가능성을 적절히 반영하여 확률을 조절하고 있음을 의미한다.

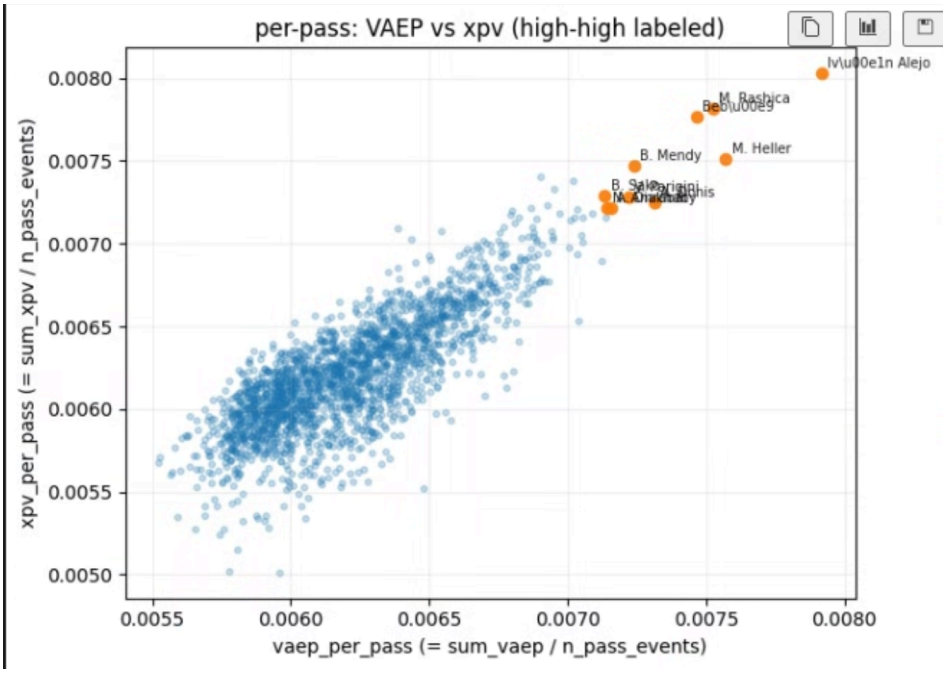


xPass 모델에서의 잔차는 xAction 모델과 동일한 맥락에서 예측된 확률과 실제 결과 간의 차이로 정의된다. 확률 분포 히스토그램을 살펴보면, 예측 확률은 0.8~0.9 구간에 높은 밀도를 형성하는 한편, 명확한 실패 상황에 해당하는 0.0~0.2 구간 또한 뚜렷하게 분리되어 나타난다. 이러한 분포 특성은 모델이 단순히 평균적인 확률을 출력하는 것이 아니라, 성공 가능성이 높은 상황과 실패 위험이 큰 상황을 효과적으로 구분하고 있음을 보여준다. 결과적으로 낮은 Brier Score와 LogLoss는 확률 잔차가 최소화되었음을 의미하며, 이는 이후 VAEP와 같은 기대값 기반 지표를 산출하는 데 있어 신뢰 가능한 입력 확률을 제공하는 기반이 된다.

6.2.4 베이스라인 비교

패스 성공 여부를 무작위로 예측하는 이론적 랜덤 베이스라인의 기대 AUC는 0.5에 불과하며, 단순히 전체 데이터의 평균 성공률(약 85.5%)에만 의존하여 확률을 추정하는 Naive 베이스라인의 기대 Brier Score는 약 0.1241 수준이다.

이와 비교할 때, XGBoost 모델이 최종 테스트에서 기록한 AUC 0.9759는 무작위 예측 대비 완벽에 가까운 분별력을 보여주며, Brier Score 0.0614는 빈도 기반 베이스라인 대비 오차를 절반 이하(약 50% 감소)로 줄인 압도적인 성능이다. 이는 모델이 단순히 85%라는 높은 성공 빈도를 암기한 것이 아니라, 거리·각도·압박과 같은 공간적 변수가 성공 확률에 미치는 물리적 인과관계를 효과적으로 학습했음을 명확히 보여준다. 특히 불균형 데이터 환경에서도 낮은 Brier Score와 LogLoss(0.1997)를 유지한 것은, 모델이 출력하는 확률값이 실제 현상과 매우 정교하게 보정(Calibration)되었음을 의미하며, 본 모델이 단순 승패 분류를 넘어 경기 내 기댓값(Expected Value) 산출을 위한 신뢰할 수 있는 기반 모델임을 뒷받침한다.



여기서 우리는 VAEP가 아니라 xPass를 기준으로 비정형 고가치 선수들을 정의하고, 3번째 per-pass 산점도(패스 단위 평균 xPass)를 함께 보면, 첫 번째 표의 Top 10 선수들은 공통적으로 match_rate는 낮거나 중간 수준인데도, 패스 한 번당 창출하는 xPass 이득(per-pass xPass)이 상위 구간에 밀집되어 있다는 점이 드러납니다. 이 산점도에서 다수의 선수들이 "모델이 가장 확률 높게 추천하는 패스" 대신, 예측 분포의 꼬리(tail)에 해당하는 비정형 패스를 반복적으로 선택함에도 불구하고, 실제 결과 기준으로는 모델 기대치를 지속적으로 초과하는 xPass를 기록하고 있어, 이들의 의사결정이 단순한 '리스크 많은 변칙 패스'가 아니라 모델이 과소평가한 고효율 선택임을 보여줍니다. 특히 우리 연구의 실제 데이터(2017–18 시즌 상위 리그 전체 패스, xPass·match_rate·per-pass xPass를 모두 계산한 패스 단위 코호트) 위에서 이런 패턴이 뚜렷하게 나타난다는 것은, Top 10 선수들이 기존 문헌에서 보고된 Creative High-Value Players처럼 "모델과 덜 비슷하게 플레이하지만, 패스 한 번당 기대를 크게 초과하는 창의적 플레이어"라는 점에서 맥락적으로 완전히 일치하며, xPass 기반 접근이 이런 비정형 고가치성을 정량적으로 포착할 수 있음을 실증적으로 뒷받침합니다.

7. 결론 및 한계

7.1 결론

본 프로젝트에서는 Wyscout 이벤트 시퀀스를 기반으로 xAction(xAction), xPass, VAEP와의 상관관계 분석으로 이어지는 축구 행동 분석 파이프라인을 구축하고, 각 지표의 성능과 상호 관계를 체계적으로 분석하였다. 먼저 xAction 문제에서는 GRU, LSTM, Transformer 세 가지 시퀀스 모델을 동일한 입력 스키마 하에서 비교하였으며, 하이퍼파라미터 탐색 결과 Transformer가 가장 우수한 성능과 일반화 특성을 보였다. 특히 2-stage TPE 탐색을 통해 Transformer는 macro F1 기준 가장 큰 성능 향상을 달성하였고, 희귀 행동을 포함한 전반적인 행동 예측에서 안정적인 개선 추세를 나타냈다.

xAction 예측 결과를 실제 행동과 비교한 residual 분석을 통해, 단순 예측 정확도를 넘어 행동 일치율(match_rate) 이 선수의 플레이 스타일을 설명하는 유의미한 지표로 작동함을 확인하였다. 나아가 match_rate와 VAEP를 결합한 분석을 통해, 예측과 다른 비정형적 행동을 수행하면서도 높은 가치를 창출하는 Creative High-Value 선수 유형을 식별할 수 있었다. 이 범주에 포함된 선수들이 데이터 수집 시점(2017년) 기준 실제로 최고 수준의 시장가치와 커리어를 보유한 선수들이라는 점은, 본 분석이 축구 맥락에서 해석 가능한 결과를 도출했음을 뒷받침한다.

xPass 모델에서는 XGBoost 기반 확률 예측 모델을 활용하여 매우 높은 AUC-ROC와 낮은 LogLoss 및 Brier Score를 기록하였으며, 이는 불균형한 패스 성공 데이터 환경에서도 확률 예측의 분별력과 보정(calibration) 이 모두 우수함을 의미한다. 이러한 결과는 xPass 출력이 VAEP 계산에 사용되는 확률 입력으로서 충분한 신뢰도를 가진다는 점을 확인시켜 준다.

종합하면, 본 프로젝트는 축구 이벤트 시퀀스를 활용하여 행동 예측–확률추정–가치 평가로 이어지는 고급 성능 지표 학습 및 추론 파이프라인을 성공적으로 구축하였으며, 지표 간 결합 분석을 통해 선수 행동의 정형성·비정형성과 가치 창출 간의 관계를 실증적으로 분석하였다는 점에서 의의를 가진다.

7.2 한계

본 프로젝트의 주요 한계는 데이터 유형의 제약에 있다. 축구 데이터는 이벤트 데이터뿐 아니라, 모든 선수와 공의 위치를 실시간으로 기록한 트래킹 데이터를 포함할 수 있으나, 트래킹 데이터는 매우 비싼 비용으로 인한 접근성의 문제로 인해 본 분석에 포함하지 못하였다. 이로 인해 수비 압박, 오프 더 볼 움직임, 공간 점유와 같은 미시적인 전술 요소를 직접적으로 반영하지 못한 한계가 존재한다.

또한 본 분석은 단일 데이터 소스(Wyscout 이벤트)와 특정 시즌 범위에 기반하고 있어, 리그·시즌 간 일반화 가능성에 대한 추가 검증이 필요하다. 특히 Creative High-Value 선수에 대한 해석은 통계적 상관관계에 근거하므로, 인과적 해석이나 전술적 맥락까지 확장하기에는 제한이 있다.

마지막으로, nextAction 모델은 행동 type 및 category 예측에 초점을 두었으나, 향후에는 행동의 공간적 결과(정확한 위치, 방향) 까지 함께 예측하는 다변량 시퀀스 모델로 확장함으로써, 시뮬레이션 및 전술 분석 측면에서 더 풍부한 활용이 가능할 것으로 기대된다.

참고

- **VAEP**
  - 연구자: Tom Decroos, Lotte Bransen, Jan Van Haaren, Jesse Davis 등
  - 발표 시기: 2018–2019 (KDD, arXiv)
  - 핵심: 행동 가치 정량화 via 득점/실점 확률 변화 (Tom Decroos)
- **xPass / Expected Pass Completion**
  - 연구자: Anzer, Bauer 등 (2022)
  - 발표 시기: 2022
  - 핵심: 맥락 기반 패스 성공 확률 예측 (ResearchGate)
- **xAction / Next-Event Prediction**
  - 연구자: Mendes-Neves, Meireles, Mendes-Moreira 등
  - 발표 시기: 2024
  - 핵심: LLM 영감을 받은 시퀀스 기반 경기 이벤트 예측 (arXiv)